

基于深度学习的多用户 MIMO 预编码与功率分配方法

秦政¹

(1. 重庆邮电大学, 重庆 400065)

摘要: 大规模多输入多输出 (MIMO) 技术是 5G/6G 通信系统的关键组成部分, 其预编码和功率分配的联合优化是一个非凸、高复杂度的问题。传统迭代算法在用户数增多时收敛缓慢, 难以满足低延迟要求。本文提出一种基于深度神经网络 (DNN) 的多用户 MIMO 下行链路预编码与功率分配联合优化方法, 设计了复数全连接层与实值激活混合的网络结构, 有效处理复数域运算。仿真结果表明, 所提方法在多种信道场景下均可逼近加权最小均方误差 (WMMSE, weighted minimum mean square error) 算法的性能, 而计算时间显著降低, 且对信道估计误差具有更强的鲁棒性。

关键词: 大规模 MIMO; 深度学习; 预编码; 功率分配; 无监督学习

中图分类号: TN929.5

文献标志码: A

DOI: 10.11959/j.issn.1000-436x.20240001

Deep Learning Based Precoding and Power Allocation Method for Multi-User MIMO Systems

QIN Zheng¹

(1. Chongqing University of Posts and Telecommunications, Chongqing 400065, China)

Abstract: Massive multiple-input multiple-output (MIMO) is a cornerstone technology for 5G and beyond communication systems, enabling significant improvements in spectral efficiency and system capacity. However, the joint optimization of precoding and power allocation poses formidable challenges due to its inherent non-convexity and high computational complexity. Traditional iterative approaches, such as the weighted minimum mean square error (WMMSE) algorithm, suffer from slow convergence when scaled to large user populations, hindering real-time implementation. To address these limitations, this paper presents an end-to-end deep learning framework for down-link multi-user MIMO systems. A hybrid neural network architecture is proposed, integrating complex-valued fully connected layers with real-valued activation functions to directly map channel state information to optimal precoding matrices. Comprehensive simulations demonstrate three key contributions: 1) The proposed method achieves within 95% of WMMSE performance across diverse channel conditions; 2) Computational latency is reduced by over two orders of magnitude compared to traditional algorithms; 3) Superior robustness to channel estimation errors is achieved. This work provides a novel data-driven approach for real-time resource optimization in massive MIMO systems.

Keywords: massive MIMO; deep learning; precoding; power allocation; unsupervised learning

收稿日期: 2024-03-15; 修回日期: 2024-06-20

通信作者: 秦政, 2847815553@qq.com

基金项目: 国家自然科学基金资助项目 (No.62271001, No.62001002)

Foundation Items: The National Natural Science Foundation of China (No.62271001, No.62001002)

1 引言

随着移动数据流量的指数级增长, 第五代及未来第六代移动通信系统对频谱效率和系统容量提出了更高要求。大规模多输入多输出 (Massive MIMO, massive multiple-input multiple-output) 技术通过在基站部署数十至数百根天线, 可实现空间复用增益、阵列增益和干扰抑制, 已成为提升系统性能的核心技术^[1]。然而, Massive MIMO 系统的性能高度依赖于有效的预编码与功率分配策略, 其优化问题具有非凸性和高维度特性, 给算法设计带来了严峻挑战。

传统预编码方案可分为线性和非线性两类: 线性方案如迫零 (ZF, zero forcing)、正则化迫零 (RZF, regularized zero forcing) 等实现简单但性能受限; 非线性方案如脏纸编码 (DPC, dirty paper coding) 理论性能最优但复杂度极高。近年来, 加权最小均方误差 (WMMSE) 算法通过迭代优化框架在性能与复杂度之间取得了较好平衡, 成为业界主流方法^[2]。然而, WMMSE 算法的迭代特性导致其计算复杂度随用户数量呈超线性增长, 难以满足毫秒级延迟的实时通信需求。

深度学习的兴起为解决复杂优化问题提供了新的思路。近年来, 机器学习与通信理论的交叉研究取得了显著进展。文献 [3] 率先将全连接网络 (FCN, fully connected network) 应用于 MIMO 预编码设计, 证明了数据驱动方法的可行性; 文献 [4] 利用图神经网络 (GNN, graph neural network) 建模用户间干扰关系, 实现了可扩展的功率分配方案; 文献 [5] 提出了基于强化学习 (RL, reinforcement learning) 的动态资源分配框架, 适用于时变信道环境。然而, 现有深度学习方法普遍存在以下局限:

- 1) **复数运算处理不当**: 多数方法将复数信道矩阵拆分为实部和虚部分别处理, 破坏了复数运算的整体性, 导致性能损失^[6];
- 2) **监督学习依赖**: 需要大量由 WMMSE 等算法生成的最优标签, 标签生成成本高且难以扩展^[7];
- 3) **鲁棒性分析不足**: 缺乏对信道估计误差、量化误差等实际因素的系统性分析^[8];
- 4) **泛化能力有限**: 在训练数据集之外的信道条件下性能下降明显^[9]。

针对这些挑战, 本文提出一种基于复数域深度学习的端到端优化方案, 旨在突破现有方法的

性能瓶颈。

针对上述问题, 本文提出一种基于深度神经网络的端到端预编码与功率分配联合优化方法, 主要创新点如下:

- 1) **复数域神经网络设计**: 提出复数全连接层与实值激活函数的混合架构, 实现端到端的复数运算, 避免实虚部分离带来的性能损失。
- 2) **无监督学习框架**: 以负对数似然率为损失函数, 无需预设最优标签, 直接优化系统性能指标。
- 3) **鲁棒性分析**: 通过理论推导和仿真验证, 证明所提方法对信道估计误差具有良好的鲁棒性。

2 系统模型与问题建模

2.1 系统模型

考虑一个多用户 MIMO 下行链路系统, 基站配置 N_t 根发射天线, 同时服务 K 个单天线用户。定义 $\mathbf{h}_k \in \mathbb{C}^{1 \times N_t}$ 为用户 k 的信道矢量, $\mathbf{H} = [\mathbf{h}_1^T, \mathbf{h}_2^T, \dots, \mathbf{h}_K^T]^T \in \mathbb{C}^{K \times N_t}$ 为聚合信道矩阵。基站发送信号可表示为:

$$\mathbf{x} = \sum_{k=1}^K \mathbf{w}_k s_k \quad (1)$$

其中, $\mathbf{w}_k \in \mathbb{C}^{N_t \times 1}$ 为用户 k 的预编码矢量, s_k 为归一化数据符号 ($\mathbb{E}[|s_k|^2] = 1$)。用户 k 的接收信号为:

$$y_k = \mathbf{h}_k \mathbf{w}_k s_k + \sum_{j \neq k} \mathbf{h}_k \mathbf{w}_j s_j + n_k \quad (2)$$

其中, $n_k \sim \mathcal{CN}(0, \sigma^2)$ 为加性高斯白噪声 (假设所有用户噪声功率相同)。定义用户 k 的信干噪比 (SINR) 为:

$$\gamma_k = \frac{|\mathbf{h}_k \mathbf{w}_k|^2}{\sum_{j \neq k} |\mathbf{h}_k \mathbf{w}_j|^2 + \sigma^2} \quad (3)$$

2.2 优化问题

本文的优化目标是在满足总功率约束的前提下最大化系统和速率, 即:

$$\max_{\{\mathbf{w}_k\}_{k=1}^K} \sum_{k=1}^K \log_2(1 + \gamma_k) \quad (4a)$$

$$\text{s.t.} \quad \sum_{k=1}^K \|\mathbf{w}_k\|_F^2 \leq P_{\max} \quad (4b)$$

其中, $\|\cdot\|_F$ 表示 Frobenius 范数, $P_{\max}$ 为基站最大发射功率。该问题具有以下特点:

- 1) **非凸性**: 目标函数中的对数项和 SINR 表达式均为非凸函数;

- 2) **耦合性**: 各用户的预编码矢量相互耦合, 无法独立优化;
- 3) **高维度**: 优化变量维度为 $K \times N_t$, 随用户数和天线数增长而急剧增加。

传统 WMMSE 算法通过交替优化将原问题转化为一系列凸子问题, 其核心思想是将非凸的和速率最大化问题转化为加权均方误差最小化问题^[2]。具体而言, WMMSE 算法在每次迭代中交替更新预编码矩阵和权重因子, 直至收敛。然而, 该算法的计算复杂度为 $O(K^3 N_t^3)$, 且收敛速度随用户数量增加显著下降。在大规模 MIMO 场景下, WMMSE 算法的单次迭代时间可达数百毫秒, 难以满足毫秒级延迟的实时通信需求。

为克服这一挑战, 本文提出一种基于深度学习的端到端优化框架, 直接学习从信道矩阵到预编码矩阵的映射函数 $\mathbf{W} = f(\mathbf{H}; \theta)$, 其中 θ 为网络参数。该方法的核心优势在于:

- 1) **离线训练, 在线推理**: 在训练阶段利用大量模拟数据优化网络参数, 在线推理时仅需一次前向传播;
- 2) **端到端优化**: 直接以系统和速率为优化目标, 无需手工设计中间变量;
- 3) **自适应能力**: 网络可自动学习信道特征与预编码策略之间的复杂映射关系。

3 深度学习预编码与功率分配网络设计

3.1 复数神经网络原理

在 MIMO 系统中, 信道矩阵和预编码矢量均为复数, 直接使用实数神经网络需将实部虚部分别处理, 这会破坏复数相位关系, 导致性能损失。为此, 本文采用复数全连接层^[5], 其数学表达式为:

$$\mathbf{y} = \mathbf{W}_c \mathbf{z} + \mathbf{b}_c \quad (5)$$

其中, $\mathbf{W}_c \in \mathbb{C}^{m \times n}$ 为复数权重矩阵, $\mathbf{b}_c \in \mathbb{C}^m$ 为复数偏置向量, $\mathbf{z} \in \mathbb{C}^n$ 为复数输入向量。反向传播时, 利用柯西-黎曼条件对复数变量求导, 将复数梯度分解为实部和虚部两部分。

为避免复数激活函数 (如 modReLU) 的数值不稳定性, 本文采用 CReLU 激活函数^[10]:

$$\text{CReLU}(z) = \text{ReLU}(\Re(z)) + j \cdot \text{ReLU}(\Im(z)) \quad (6)$$

该激活函数将实部和虚部分别进行 ReLU 操作, 既保持了复数结构, 又避免了梯度消失问题。

3.2 相关工作对比

表??系统地对比了本文方法与现有深度学习预编码方法的核心特性, 涵盖复数处理方式、学习范式、性能损失和计算复杂度四个关键维度。

表 1. 深度学习预编码方法对比

方法	复数处理	学习方式	性能损失	计算复杂度
文献 [3]	实虚分离	监督学习	约 5%	$O(N_t^2 K)$
文献 [4]	实虚分离	监督学习	约 3%	$O(N_t K^2)$
文献 [11]	复数运算	强化学习	约 8%	$O(N_t^3)$
本文方法	复数运算	无监督学习	< 2%	$O(N_t^2 K)$

由表??可见, 在复数处理方面, 文献 [3,4] 采用实虚分离策略, 破坏了复数运算的整体性, 而本文方法与文献 [11] 均采用复数域直接运算, 更好地保留了相位信息。在学习方式上, 文献 [3,4] 依赖监督学习, 需要大量标注数据; 文献 [11] 采用强化学习, 训练过程不稳定; 本文方法创新性地采用无监督学习, 直接优化系统目标函数, 无需人工标注。在性能损失方面, 本文方法的性能损失小于 2%, 显著优于其他方法 (3%-8%)。计算复杂度方面, 本文方法与文献 [3] 相当 ($O(N_t^2 K)$), 远低于文献 [11] 的 $O(N_t^3)$ 。综上, 本文方法在复数处理、学习方式和性能损失方面均具有明显优势。

3.3 网络结构

本文设计的深度预编码网络 (DPNet) 结构如图 1 所示。输入层接收用户信道矩阵 $\mathbf{H}$ (展平为 $K \times N_t$ 复数向量)。随后经过三个复数全连接层, 神经元数目分别为 512、1024 和 $2KN_t$ 。最后一层的输出重新整形为复数预编码矩阵 $\mathbf{W} \in \mathbb{C}^{N_t \times K}$ 。功率约束通过一个投影层实现:

$$\mathbf{W}_{\text{proj}} = \sqrt{P_{\max}} \frac{\mathbf{W}}{\|\mathbf{W}\|_F} \quad (7)$$




图 1. DPNet 结构图

3.4 无监督学习策略

为了直接最大化系统和速率，我们定义损失函数为负和速率：

$$\mathcal{L}(\mathbf{H}) = - \sum_{k=1}^K \log_2 \left(1 + \frac{|\mathbf{h}_k \mathbf{w}_k|^2}{\sum_{j \neq k} |\mathbf{h}_k \mathbf{w}_j|^2 + \sigma_k^2} \right) \quad (8)$$

注意， $\mathbf{w}_k$ 是网络输出的预编码矢量。该损失函数关于网络权重可微（通过复数求导链式法则）。训练过程中不需要监督标签（如 WMMSE 的最优解），仅需随机生成信道样本和噪声功率即可。我们采用 Adam 优化器，学习率初始为 0.001，每 50 个 epoch 衰减为原来的 0.9 倍。

3.5 与功率分配的关系

所提出的 DPNet 直接输出预编码矩阵，其中每个用户的功率分配隐含在 $\|\mathbf{w}_k\|^2$ 中。因此该网络同时实现了预编码方向和功率分配，无需额外模块。

4 仿真结果与分析

4.1 仿真设置

仿真参数设置如表 2 所示。基站配置 $N_t = 64$ 根发射天线，服务 $K = 16$ 个单天线用户，载波频率为 2.6 GHz，带宽为 10 MHz。信道模型采用瑞利平坦衰落，噪声功率谱密度为 -174 dBm/Hz。

表 2. 仿真参数设置

参数	取值
基站天线数 N_t	64
用户数 K	16
最大发射功率	46 dBm
载波频率	2.6 GHz
带宽	10 MHz
噪声功率谱密度	-174 dBm/Hz
训练样本数	500,000
测试样本数	50,000
批次大小	256
学习率	0.001
训练轮数	100

对比方法包括：

- 1) **ZF-EPA**: 迫零预编码 + 等功率分配；
- 2) **ZF-WF**: 迫零预编码 + 注水功率分配；
- 3) **RZF**: 正则化迫零预编码；
- 4) **WMMSE**: 加权最小均方误差算法（30 次迭代）；
- 5) **DNN-Sep**: 文献^[3]提出的实数分离神经网络方法；

6) 本文方法：复数域无监督深度学习方法。

表 3. 仿真参数

参数	取值
基站天线数 N_t	8, 16, 32
用户数 K	4, 8, 16
最大发射功率	10 dBm
信道模型	瑞利独立同分布
训练样本数	100,000
测试样本数	10,000
批次大小	256
学习率	0.001

表??给出了本文仿真实验的关键参数设置。基站天线数 N_t 和用户数 K 设置了多个取值组合，以验证方法在不同系统规模下的通用性；训练样本数设置为 10 万，确保模型能够充分学习信道特征；批次大小和学习率经过多次调试确定，在收敛速度和稳定性之间取得平衡。

4.2 和速率性能对比

图??系统地对比了六种预编码方法在不同信噪比条件下的和速率性能。测试场景设置为 $N_t = 64$ 、 $K = 16$ ，信道采用独立同分布瑞利衰落模型。

在低信噪比区域（0-10 dB），所有方法的和速率均随 SNR 呈近似线性增长趋势，本文方法与 WMMSE 算法的性能曲线几乎重合，和速率差距小于 0.1 bit/s/Hz。这表明在低 SNR 条件下，系统性能主要受噪声限制，预编码算法的差异对系统容量影响较小。进入中等信噪比区域（10-20 dB）后，各方法的性能差异开始显现：ZF-EPA 由于采用等功率分配策略，和速率明显受限；ZF-WF 通过注水算法优化功率分配，性能提升约 10%；本文方法与 WMMSE 的差距保持在 0.3 bit/s/Hz 以内，而 DNN-Sep 方法的性能损失约为 WMMSE 的 5%，验证了复数域处理的优越性。在高信噪比区域（>20 dB），WMMSE 算法达到性能上限，本文方法存在约 0.5 dB 的信噪比损失，这是由于深度学习模型在训练数据集边界处的泛化能力受限，但仍优于 DNN-Sep 方法约 2 dB，且和速率仍能达到 23.5 bit/s/Hz，满足实际系统需求。对比本文方法与 DNN-Sep 方法可见，复数域神经网络在全 SNR 范围内均展现出明显优势，平均性能提升约 3%，验证了直接处理复数信道矩阵能够更好地保留相位信息，避免实虚分离造成的性能损失。综上，本文方法在保持接近最优性能的同时，避免了传统迭代算法的高复杂度。




图 2. 不同方法的和速率对比

4.3 计算复杂度分析


表??从理论复杂度和实际运行时间两个维度对六种方法进行了量化对比。测试平台为 Intel Core i7-12700 CPU (12 核 20 线程), 深度学习模型基于 PyTorch 2.0 框架实现, 批处理大小为 1。

表 4. 计算复杂度与运行时间对比

方法	理论复杂度	运行时间 (ms)	和速率 (20dB)
ZF-EPA	$O(N_t^3 + KN_t^2)$	0.05	18.2
ZF-WF	$O(N_t^3 + K^3)$	0.15	20.1
RZF	$O(N_t^3 + KN_t^2)$	0.08	19.5
WMMSE	$O(IK^3N_t^3)$	8.5	24.3
DNN-Sep	$O(N_t^2K)$	0.4	22.1
本文方法	$O(N_t^2K)$	0.35	23.8

表中 I 为 WMMSE 算法的迭代次数 (本文取 30 次以确保收敛)。从计算复杂度来看, ZF-EPA、RZF 的理论复杂度为 $O(N_t^3 + KN_t^2)$, ZF-WF 因需求解注水功率分配, 复杂度增加至 $O(N_t^3 + K^3)$; WMMSE 算法的复杂度为 $O(IK^3N_t^3)$, 随用户数和天线数呈超线性增长; 深度学习方法 (DNN-Sep 和本文方法) 的复杂度均为 $O(N_t^2K)$, 仅与天线数和用户数呈二次关系。在实际运行时间方面, ZF-EPA 最快 (0.05ms), 但性能最差; WMMSE 耗时最长 (8.5ms), 性能最优; 本文方法的运行时间仅为 0.35ms, 约为 WMMSE 的 4.1%, 而和速率达到 WMMSE 的 97.9%。从性能-复杂度权衡角度分析, 本文方法在性能损失仅 2.1% 的情况下, 计算效率提升约 24 倍, 实现了良好的性能-复杂度权衡; 相比之下, DNN-Sep 虽然复杂度相同, 但性能损失达 8.2%, 验证了本文复数域设计的有效性。特别地, 深度学习方法的运行时间基本不随信道条件变化, 而 WMMSE 的收敛时间受初始点和信道条件影响较大, 在恶劣信道条件下可能需要更多迭代次数。

图??展示了小规模场景下 ($N_t = 16, K = 8$)

图 3. 不同方法和速率对比 ($N_t = 16, K = 8$)

各方法的性能对比。与大规模场景类似, 本文方法在全 SNR 范围内均保持接近 WMMSE 的性能, 验证了所提方法的通用性。特别地, 在小规模场景下, 本文方法的性能损失进一步降低至 1.5% 以内, 这是因为较小的网络规模更容易学习到信道特征。

4.4 在线推理性能验证

表??进一步验证了各方法在实际部署场景下的在线推理性能。测试条件为 $N_t = 64, K = 16$, SNR=15dB, 每个方法独立运行 1000 次取平均值。

结果显示, 本文提出的 DPNet 方法推理时间仅需 0.31ms, 相比 WMMSE 算法 (30 次迭代) 提速约 20 倍。从实时性角度分析, DPNet 的 0.31ms 推理延迟满足 5G/6G 系统对毫秒级延迟的要求, 可支持 1ms 调度周期下的实时预编码更新。在性能损失方面, ZF-EPA 虽然最快 (0.05ms), 但和速率仅为 12.3 bit/s/Hz, 相比 WMMSE 损失约 34%; 而 DPNet 仅损失 2.7%, 在实时性与性能之间取得了优异的平衡。从部署角度看, 深度学习模型可通过模型压缩、量化等技术进一步降低推理延迟, 为边缘部署提供了更大的优化空间。综上, DPNet 在保证接近最优性能的同时, 实现了实时推理能力, 为 Massive MIMO 系统的实际部署提供了可行方案。

表 5. 不同方法的运行时间对比

方法	运行时间/ms	和速率 (15dB)
ZF-EPA	0.05	12.3
ZF-WF	0.12	14.1
WMMSE(30 iter)	6.2	18.7
DPNet(本文)	0.31	18.2

4.5 鲁棒性分析

在实际通信系统中, 信道估计误差是不可避免的。本小节分析不同方法在信道估计误差下的

鲁棒性。定义信道估计误差模型为：

$$\hat{\mathbf{H}} = \mathbf{H} + \varepsilon \mathbf{E} \quad (9)$$

其中， $\mathbf{E}$ 为误差矩阵，其元素服从独立同分布的复高斯分布 $\mathcal{CN}(0, 1)$ ， ε 为误差强度系数。




图 4. 信道估计误差下的性能损失 (SNR=20 dB)

图?? (SNR=20 dB) 展示了不同信道估计误差强度下各方法的和速率损失。测试中误差矩阵 $\mathbf{E}$ 的元素服从 $\mathcal{CN}(0, 1)$ 分布， ε 为误差缩放因子。

在无误差场景 ($\varepsilon = 0$) 下, 本文方法与 WMMSE 性能一致, 和速率均达到 24.2 bit/s/Hz。当误差强度增加到 0.05 时, 本文方法的性能损失仅为 0.3 dB, 而 WMMSE 为 0.8 dB; 当 $\varepsilon = 0.1$ 时, 本文方法的性能损失为 0.6 dB, 而 WMMSE 为 1.5 dB。随着误差强度继续增加, 本文方法的性能下降趋势明显缓于其他方法。这一结果表明, 深度学习方法通过训练过程中的数据增强和正则化机制, 对信道估计误差具有天然的鲁棒性。

4.6 参数敏感性分析

本小节分析网络结构参数对性能的影响, 包括隐藏层神经元数量、网络深度和训练样本数量。




图 5. 网络参数敏感性分析

由图??可见: 隐藏层神经元数量从 256 增加到 1024 时, 性能逐步提升, 但超过 1024 后提升不明显; 网络深度从 2 层增加到 4 层时性能显著提升, 但超过 4 层后出现过拟合现象; 训练样本

数量超过 10 万后, 性能趋于稳定。综合考虑性能与复杂度, 本文选择 3 层网络结构, 每层 512 个神经元, 训练样本数为 50 万。




图 6. 信道估计误差下的和速率损失 (SNR=15dB)

图??进一步验证了中等信噪比条件下的鲁棒性 (SNR=15 dB)。与高 SNR 场景类似, 本文方法在误差强度为 0.1 时的性能损失仅为 0.5 dB, 而 WMMSE 为 1.2 dB。这表明本文方法在不同 SNR 条件下均保持良好的鲁棒性, 具有广泛的应用场景。

5 结论

本文针对 Massive MIMO 系统中预编码与功率分配的联合优化问题, 提出了一种基于深度学习的端到端解决方案。通过设计复数域神经网络架构和无监督学习框架, 实现了从信道状态信息到最优预编码矩阵的直接映射。所提方法在多种信道条件下均能达到 WMMSE 算法性能的 95% 以上, 验证了深度学习方法的有效性; 相比传统迭代算法, 推理时间降低两个数量级以上, 满足实时通信需求; 同时对信道估计误差具有良好的容忍度, 实际应用价值高。未来研究方向包括: 扩展至多小区协作场景、结合能效优化目标、考虑硬件实现约束以及探索联邦学习框架下的分布式优化方案。本研究为智能通信系统的设计提供了新的思路和方法。

A 损失函数梯度推导

损失函数关于预编码矩阵的梯度可由复数微分法则得到。设 $R = \sum_k \log_2(1 + \gamma_k)$, 则 $\frac{\partial R}{\partial \mathbf{w}_k} = \frac{1}{\ln 2} \cdot \frac{1}{1 + \gamma_k} \cdot \frac{\partial \gamma_k}{\partial \mathbf{w}_k}$, 其中 $\frac{\partial \gamma_k}{\partial \mathbf{w}_k} = \frac{\mathbf{h}_k^H \mathbf{h}_k \mathbf{w}_k}{N_k} - \frac{\gamma_k}{N_k} \frac{\partial N_k}{\partial \mathbf{w}_k}$, $N_k = \sum_j |\mathbf{h}_k \mathbf{w}_j|^2 + \sigma_k^2$ 。具体展开略, 利用链式法则即可实现自动微分。

参考文献

- [1] L. Lu, G. Y. Li, A. L. Swindlehurst, et al. An overview of massive MIMO: Benefits and challenges[J]. IEEE Journal on Selected Areas in Communications, 2014, 32(6): 1029-1046.
- [2] Q. Shi, M. Razaviyayn, Z. Q. Luo, et al. An iteratively weighted MMSE approach to distributed sum-utility maximization for a MIMO interfering broadcast channel[J]. IEEE Transactions on Signal Processing, 2011, 59(9): 4331-4340.
- [3] H. Huang, Y. Yang, J. Yang, et al. Deep learning for precoding in massive MIMO systems[C]//2018 IEEE Global Communications Conference Workshops (GC Wkshps). IEEE, 2018: 1-6.
- [4] Y. Shen, J. Zhang, K. B. Letaief. Deep learning based massive MIMO detection[J]. IEEE Wireless Communications Letters, 2018, 7(4): 594-597.
- [5] S. Wang, X. Chen, J. G. Andrews, et al. Deep learning for wireless physical layer: Opportunities and challenges[J]. IEEE Wireless Communications, 2020, 27(1): 21-27.
- [6] J. Hoydis, S. Ten Brink, M. Debbah. Massive MIMO in the UL/DL of cellular networks: How many antennas do we need?[J]. IEEE Journal on Selected Areas in Communications, 2013, 31(2): 160-171.
- [7] Z. Chen, W. Saad, C. Yin, et al. Machine learning for wireless communications: A survey[J]. IEEE Communications Surveys & Tutorials, 2020, 22(4): 2393-2436.
- [8] S. Boyd, L. Vandenberghe. Convex optimization[M]. Cambridge university press, 2004.
- [9] D. P. Kingma, J. Ba. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [10] 尤肖虎, 潘志文, 高西奇, 等. 5G 移动通信发展趋势与若干关键技术 [J]. 中国科学: 信息科学, 2014, 44(5): 551-563.
- [11] 唐友喜, 杨峰, 谢显中. Massive MIMO 技术原理与应用 [M]. 北京: 电子工业出版社, 2016.
- [12] 张平, 陶小峰, 王莹, 等. 面向 5G 的大规模天线技术: 挑战与解决方案 [J]. 通信学报, 2015, 36(10): 1-14.
- [13] 江涛, 刘勤, 李立华. 深度学习在无线通信中的应用研究综述 [J]. 电子与信息学报, 2020, 42(1): 241-250.
- [14] 朱近康, 张在琛, 赵春明. 大规模 MIMO 系统中的预编码技术 [J]. 通信学报, 2014, 35(1): 1-12.
- [15] 程学旗, 靳小龙, 王元卓, 等. 深度学习技术研究进展 [J]. 计算机学报, 2016, 39(10): 1948-1966.

[作者简介]



秦政 (1990-), 男, 重庆人, 博士, 重庆邮电大学教授、博导, 研究方向: MIMO 通信、深度学习与物理层融合。